01 / SKN_FINAL · TrueFit

sLLM 미수행 사유와 API 기반 대체 활용

팀의 결정
개발 과정에서 sLLM을 별도로 도입할 만큼 활용할 부분이 크지 않다고 판단하여 사용하지 않았다. 현재 서비스는 관리형 모델 API를 활용하고, 추천 점수·호환성·예산 판단은 규칙 엔진으로 처리한다.

미수행 사유와 설계 근거

TrueFit의 AI 역할은 자연어 조건 해석, 견적 이미지·텍스트 추출, 근거 검색 및 설명 생성에 집중되어 있다. 핵심 판단은 코드가 담당하도록 역할을 나누었으며, 현재 요구 기능을 API로 연결했다. 이러한 구조가 팀의 sLLM 활용 필요성 판단을 뒷받침한다.

자체 sLLM 학습·미세조정·자체 서빙은 수행 실적으로 제시하지 않는다. GPU·예산·일정 부족을 결정 사유로 추가하지 않으며, API가 sLLM보다 우수하다는 직접 비교 결과도 주장하지 않는다.

기능별 활용과 검증 경계

기능	대체 모델 활용	검증·판정 경계
조건·결과 대화	OpenAI API 및 Strands 도구 호출로 조건 해석·조회·교체 요청 처리	허용된 도구와 서비스 로직이 실제 조회·변경 수행
견적 사양 추출	텍스트·비전 API로 부품명·사양 문구 추출	구조 검증 후 카탈로그 매칭·호환 판정은 코드가 처리
추천 설명·스펙 검색	계산 결과 설명, web_search 후 관련성·지원 필드 검증	근거·출처를 확인하고 기능별 규칙 대체 또는 오류 처리
리뷰·사용기 활용	API 임베딩으로 근거 검색, 사용기 체감 문장을 구조화	추출·검색 결과와 규칙 기반 집계·추천 점수를 구분

설정 및 구현 해석

저장소 예시 대화 모델과 이미지 모델 기본값은 **gpt-6-luna**, 임베딩 기본 설정은 **text-embedding-3-small**이다. 실제 사용 모델은 실행 환경과 기능 플래그에 따라 달라진다. MOCK_MODE 및 테스트용 해시 벡터는 실 API 성능 평가에서 분리한다. JSON Schema 요청과 Pydantic 검증, 시간·동시성 제한이 구현되어 있지만, 구현 존재만으로 품질 통과를 의미하지는 않는다.

근거: 팀 확인(2026-10-14 본 대화), src/config.py, .env.example, src/clients/llm_client.py, src/agent/conditions_agent.py, src/agent/spec_extraction_agent.py, src/engine/stage5_explain.py, src/services/live_spec_lookup.py, src/rag/embedding.py, src/agent/peripheral_post_agent.py.

02 / SKN_FINAL · TrueFit

확인된 평가 증거와 대체 모델 평가 방식

1. 기존 기록의 범위

확인된 기록	의미와 한계
엔진 비교: 126개 요청 중 정상 추천 108건(85.7%), 부적격 17건, 후보 부족 1건. 정상 추천의 필수 조건 위반 0건.	2026-10-13 기존 보고서 수치다. LLM을 연결하지 않은 규칙 엔진 검증이므로 85.7%를 API 모델 정확도로 해석하지 않는다.
사용기 평가 manifest: 정상 30편·비사용기 10편. 확인 시점 A1-1·F1에 각 1회 모델 실행 기록 존재.	40편 평가 완료를 뜻하지 않는다. 공격 입력·장문·실사용자 데이터가 부족하며, 정답 대조·반복 평가 전에는 정확도나 F1을 확정할 수 없다.
실호출 및 보호 장치 테스트 코드 존재	이번 문서 작업에서 테스트를 실행하지 않았다. 현재 API 종합 품질·비용·지연의 완료 결과로 제시하지 않는다.

2. 동일 조건 비교 평가 제안

비교군: 규칙 기준선(지원 과제만), 현재 API 구성, 대체 API 모델을 비교한다. 입력·프롬프트·도구·스키마·가능한 검색 근거를 고정하고 모델만 바꾼다. 자체 sLLM과의 비교 실험을 수행한 것으로 기록하지 않는다.

데이터와 반복: 기존 40편은 원문 기준 정답을 확정한 뒤 사용하고, 공격 입력·장문·실제 사용자 사례를 보강한다. 개발용과 평가용 데이터를 분리하며 비결정적 과제는 동일 입력 3회 반복한다. 사용기 40편이면 비교군당 120회 실행이며, 실제 API 호출 수는 내부 재시도 등에 따라 더 많을 수 있다.

평가 축	측정·보고 방식
추출·분류·도구 정확성	필수 필드 정확 일치율, 라벨별 Precision·Recall·F1, 정답 도구·인자·최종 상태가 모두 맞은 비율. 오류·누락 포함.
근거·검색 품질	전체 검증 가능 주장 중 근거가 뒷받침하는 비율, Recall@5, 근거 없는 단정·잘못된 제품 인용 사례.
안정성·지연·비용	전체 시도 기준 오류·폴백·공격 성공률, 사용자 요청 p50/p95, 재시도 포함 요청당 비용. API 원출력과 최종 서비스 결과 분리.

판정·재현: 정답과 근거 일치 여부는 2인 검토를 제안한다. 회차별 결과, 모델·코드·프롬프트 버전, 데이터 해시, 원출력, 검증·폴백, 토큰·비용을 보존한다. 중대한 오판·검증 우회를 우선 점검하고, 품질을 만족하는 구성 간 비용·지연을 비교한다. 수치 합격선은 공식 기준과 팀 목표 확인 후 확정한다.

근거: docs/validation/engine_policy_compare_20261012.md(본문 작성일 2026-10-13), data/eval_extraction/manifest.json 및 model_runs/{A1-1,F1}.json, scripts/eval_extraction_run.py, tests/test_llm_guard.py, tests/test_llm_deadline.py, tests/test_spec_extraction_llm_live.py. 위 평가 제안은 신규 실행 결과가 아니다.

03 / SKN_FINAL · TrueFit

평가 기준 대응 및 제출용 설명 문안

공식 평가표의 항목명·배점은 제공되지 않았다. 아래는 일반적인 평가 관점에 대한 대응안이며, 공식 기준 충족이나 대체 인정 여부를 확정하지 않는다.

평가 관점	제시할 증거와 수행 범위
sLLM 학습·미세조정·서빙	미수행 사유와 API 대체 구조를 명시한다. API 활용을 자체 sLLM 구축 실적으로 환산하지 않는다.
기술 선정·문제 적합성	자연어 해석·추출·서술과 규칙 판정의 역할 분담, 기능별 모델 연동 코드를 제시한다.
데이터·RAG·도구 활용	임베딩 검색, 도구 호출, 구조화 추출·근거 검증을 설명한다. 구현 경로와 테스트·미연결 경로를 구분한다.
정량 평가·재현성	기존 엔진 검증과 일부 모델 실행 기록을 제시한다. API 품질은 별도 동일 조건 평가와 원본 로그로 보강한다.
서비스 안정성	시간 제한·동시성 제어·검증·기능별 실패 처리 코드를 제시한다. 실제 장애·부하 검증 완료 여부는 별도 표기한다.

제출용 설명 문안

본 팀은 TrueFit 개발 과정에서 sLLM을 별도로 도입할 만큼 활용할 부분이 크지 않다고 판단하여 자체 sLLM 학습·서빙을 수행하지 않았습니다. 자연어 해석, 이미지 사양 추출, 근거 검색 및 설명 생성에는 관리형 모델 API를 활용하고, 추천 점수·호환성·예산 판단은 규칙 엔진으로 처리했습니다.

API 출력은 구조 검증과 기능별 실패 처리로 통제합니다. 기존 엔진 검증 결과와 모델 실행 기록을 제시하되, 이를 sLLM 수행 실적이나 API 종합 성능 평가 완료로 주장하지 않습니다. 대체 모델의 적절성은 동일 데이터·프롬프트·도구 조건에서 정확성, 근거 충실도, 안정성, 지연 및 비용을 분리 평가하는 방식으로 확인할 계획입니다.

최종 제출 전 보완

공식 평가표 원문과 해당 항목·배점, 실제 배포 모델·활성 설정, 확정된 데이터·정답, 반복 평가 결과와 원본 로그를 묶어 제출한다. sLLM 수행 자체가 필수라면 미충족 범위를 명시하고 대체 증거의 인정 여부를 평가 담당자에게 확인한다.

검토 범위 및 출처

2026-10-14 작업 트리(peripheral, HEAD 7678cc1)의 읽기 검토를 바탕으로 한 요약이다. 기존 미커밋 변경이 있는 상태였으며 실제 배포 환경변수·운영 로그는 확인하지 않았다. 문서 작성 과정에서 소스 수정, DB 접근, pytest 실행, 유료 API 호출은 수행하지 않았다.