01 / 검토 요약

sLLM 미수행 사유 및 API 기반 대체 모델 활용·평가 방안

SKN_FINAL · TrueFit 프로젝트 | 평가 제출용 설명 자료

핵심 판단

팀은 개발 과정에서 sLLM을 별도로 도입할 만큼 활용할 부분이 크지 않다고 판단하여 사용하지 않았다. 현재는 자연어 처리·이미지 추출·설명 생성 등에 관리형 모델 API를 활용하고, 추천 점수와 호환성 등 핵심 판단은 코드로 처리한다. [S1, S2, S5]

이 문서가 입증하는 범위

자체 sLLM의 학습·미세조정·로컬 서빙을 수행한 것으로 기재하지 않는다. 대신 **문제에 맞는 모델 활용, 구조화 출력과 도구 연동, 근거 검색, 결과 검증, 운영 안정성**을 저장소 증거로 설명한다. 모델 품질은 규칙 엔진의 정확성과 분리하여 평가한다.

구분	현재 확인 내용
팀 확인	sLLM의 실질적인 활용 필요성이 크지 않아 미도입. 2026-10-14 사용자 설명에 근거한다.
구현 확인	OpenAI SDK 및 Strands 연동, 텍스트·비전·검색 호출, API 임베딩, 검증·오류 처리 코드가 존재한다.
평가 기록	기존 엔진 비교 보고서와 일부 모델 실행 파일이 있다. 통합된 API 모델 품질 평가의 완료 근거는 확인하지 못했다.
정합성 한계	공식 평가표의 항목명·배점은 미제공이다. 이 문서의 평가 매핑과 목표치는 제안이며, 공식 기준 충족을 확정하지 않는다.

검토 기준: 2026-10-14 작업 트리, 브랜치 peripheral, HEAD 7678cc1. 기존 미커밋 변경이 있는 상태를 읽었다. 배포 환경변수와 실제 운영 로그는 확인하지 않았으며, 코드상 기본 설정을 실제 운영 설정으로 단정하지 않는다.

작성 범위: 저장소 읽기 및 PDF 생성만 수행. 소스 수정, DB 접근, pytest 실행, 유료 모델 API 호출은 수행하지 않았다.

02 / 기술 선택 사유

sLLM을 수행하지 않은 이유

확정된 팀 판단과 저장소에서 확인한 설계 근거를 구분한다.

1. 팀이 확인한 미수행 사유

"개발을 진행하면서 sLLM을 하기에는 크게 쓰일 부분이 없다고 판단해서 쓰지 않음."이라는 팀 설명을 본 문서의 공식적인 미수행 사유로 삼는다. 이는 현재 기능 범위에서의 기술 선택이며, sLLM의 일반적인 성능이나 가치가 낮다는 판단은 아니다. [S1]

2. 현재 설계와의 연결

저장소에서 확인한 사실	미수행 사유를 설명하는 연결 논리
추천·호환·예산은 코드가 계산하고 AI는 조건 해석·추출·서술을 맡도록 역할을 나눈다. [S5]	별도 학습 모델을 핵심 판정기에 투입할 필요가 크지 않은 구조다. 이 역할 분담은 팀의 활용 필요성 판단을 뒷받침한다.
대화, 이미지 사양 추출, 검색, 임베딩을 기존 API와 도구로 연결했다. [S2-S4]	현재 요구 기능을 제공하는 실행 경로가 이미 있다. 추가 sLLM 도입 효과는 동일 데이터에 대한 비교 평가로 별도 입증해야 한다.
검색 근거 검증은 프롬프트와 구조화 출력으로 적용한다고 설계 문서에 기록했다. [S7]	검색 검증을 위한 별도 critic 파인튜닝까지 수행한 것으로 설명하지 않는다. 서비스 요구에 필요한 범위로 적용했다.
구조 검증, 허용된 도구, 시간 제한 및 일부 규칙 폴백이 구현되어 있다. [S3, S6]	프로젝트의 구현 기여는 가중치 학습보다 모델을 실제 서비스에 연결하고 결과를 통제하는 데 있다.

3. 미수행 범위와 주장하지 않는 사항

본 과제에서 자체 sLLM 학습·미세조정·양자화·자체 추론 서버 구축 및 sLLM과 API의 직접 비교 실험은 수행 성과로 제시하지 않는다. GPU 부족, 예산 부족, 일정 부족, 학습 데이터 부족을 팀의 결정 사유로 추가하지 않는다. 해당 사실은 이번 확인 범위에서 확정되지 않았다.

평가 자료에 사용할 결론

sLLM 미도입은 현재 서비스에서의 추가 활용 필요성이 낮다는 팀 판단에 따른 범위 선택이다. 대체 구현의 적절성은 API 연결 여부 자체보다 과제별 정확성, 근거 일치, 실패 대응 및 비용·지연을 측정하여 설명한다.

03 / 활용 구조

대체 모델의 역할과 호출 방식

모델명은 저장소의 설정값이며, 실행 시에는 환경변수와 실제 응답 메타데이터로 다시 확인한다.

영역	API 활용 및 구현 근거	코드와의 역할 경계
조건·결과 대화	Strands OpenAIModel 및 LLM_MODEL. 조건 변경, 후보 조회·교체 등 허용 도구 연동. [S2, S4]	자연어를 도구 입력으로 변환한다. 후보 조회·변경은 서비스 도구가 수행한다.
견적 텍스트·이미지	call_llm / call_llm_vision. 비전 모델은 SPEC_EXTRACTION_IMAGE_MODEL로 분리. [S2, S3, S6]	부품 문구를 추출한다. 카탈로그 매칭과 호환 판정은 별도 코드가 맡는다.
추천 설명	stage5_explain의 초안 생성, Pydantic 검증 및 규칙 문장 대체. [S6]	계산된 결과를 설명한다. 새 점수나 호환 판정을 생성한 것으로 취급하지 않는다.
미보유 부품 검색	Responses API web_search 후 call_llm으로 관련성·지원 필드를 검증한다. [S3, S7]	출처와 구조화 결과를 저장한다. 검색 요약을 곧바로 확정 사실로 간주하지 않는다.
리뷰·가이드 검색	OpenAIEmbedder / care_guides. 기본 임베딩 설정은 text-embedding-3-small. [S2, S8]	유사한 근거를 찾는 역할이다. 해시 기반 테스트 벡터는 의미 검색 성능 증거가 아니다.
주변기기 사용기	peripheral_post_agent가 체감 문장을 구조화하고 계약 검증을 적용한다. [S9]	추출·검증 결과와 규칙 기반 집계·점수 계산을 분리한다.

설정 해석

대화 모델의 예시 설정과 이미지 모델 기본값은 **gpt-6-luna**로 기록되어 있다. LLM_MODEL은 실행 환경 주입값이며 MOCK_MODE=1 또는 기능 플래그 비활성 상태에서는 실제 API 경로가 사용되지 않을 수 있다. API로 호출한다는 사실이나 모델 이름의 경량 표기는 자체 sLLM 구축 실적을 의미하지 않는다. [S2]

생성·추출 흐름: 입력 → API/에이전트 → 구조 검증·도구 → 규칙 엔진/저장소 → 결과·근거 설명. 설명 생성처럼 규칙 엔진 뒤에서 API를 사용하는 경로도 있다. 모든 기능이 단일 순서로 실행되는 것은 아니다.

BedrockEmbedder 및 로컬 테스트 구현도 저장소에 남아 있다. 현재 리뷰·사용기 경로의 OpenAIEmbedder 사용과 구분하며, 파일 존재만으로 운영 사용을 주장하지 않는다. [S8]

04 / 검증 및 실패 대응

API 활용을 검증 가능한 구현으로 연결

검증 장치의 존재와 실제 품질 평가 통과는 서로 다른 증거다.

통제 항목	코드에서 확인한 동작	평가에서 확인할 내용
구조화 출력	JSON Schema 요청, JSON 파싱 및 호출부의 Pydantic 검증. strict=False 사용. [S3, S6]	문법·스키마 적합률과 의미 정확도를 별도로 측정한다. JSON 형식 성공만으로 정답 처리하지 않는다.
도구와 역할 제한	대화 에이전트의 도구 정의, 부품 추출과 매칭·판정의 분리. [S4-S6]	의도와 다른 도구 실행, 잘못된 인자, 요청하지 않은 상태 변경을 확인한다.
근거 연결	검색 결과의 source_url, supported_fields, 리뷰 문장 검색 경로. [S7, S8]	인용한 근거가 해당 제품·주장을 실제로 뒷받침하는지 사람이 대조한다.
시간·동시성 제한	LLM 호출 슬롯, timeout 및 deadline이 있는 경로의 시간 예산 내 재시도. [S3, S10]	429·지연·잘못된 JSON 등을 주입해 제한 시간과 오류·대체 동작을 검증한다.
폴백과 오류 노출	텍스트 추출·일부 대화·설명은 규칙 경로로 대체 가능. 이미지 추출 실패는 오류를 알리는 별도 경로. [S5, S6]	기능별 기대 동작을 정의한다. 모든 AI 기능이 동일한 폴백을 가진다고 평가하지 않는다.
실제·모의 호출 분리	MOCK_MODE 및 llm_live 마커, 테스트용 해시 임베딩 구분. [S2, S8, S11]	실 API 평가와 모킹 회귀 테스트를 별도 집계하고, 스킵을 통과로 계산하지 않는다.

검증 사례: 이미지에서 제품 번호를 잘못 읽는 경우

정답 제품 번호, 원본 이미지, API 원출력, 정규화 후 값, 카탈로그 매칭 결과를 함께 보관한다. 모델이 잘못 읽었는데 유사한 제품으로 매칭된 경우는 추출 성공으로 세지 않는다. 반대로 읽을 수 없는 항목을 비워 둔 경우는 불확실성 처리로 기록하고, 정확도 분모에서 임의로 제외하지 않는다.

기존 테스트 파일에는 시간 예산·재시도·동시성 제한, 이미지 추출, 대화 및 임베딩 실호출 검증이 있다. 이번 문서 작성에서는 해당 테스트를 실행하지 않았으므로 현재 통과 상태는 주장하지 않는다. [S10, S11]

05 / 기존 증거의 해석

확인된 결과와 아직 입증되지 않은 결과

아래 수치는 기존 파일을 읽어 요약한 값이다. 이번 작업의 신규 실험 결과가 아니다.

근거	확인된 기록	해석 가능한 범위
엔진 비교 보고서 2026-10-13 [S12]	126개 요청 중 정상 추천 108건(85.7%), 부적격 17건, 후보 부족 1건, 오류 0건. 정상 추천 108건의 필수 조건 위반 0건.	LLM을 연결하지 않은 규칙 엔진 비교다. 85.7%를 API 모델 정확도나 전체 사용자 만족도로 보고하지 않는다.
엔진 고정 시나리오 동일 보고서 [S12]	작은 메모리 카탈로그와 스텁을 사용하는 16종 시나리오의 기대값·실제값 비교가 기록되어 있다.	정책 회귀 근거다. 실 API, 실시간 외부 검색, 운영 환경 E2E를 검증한 결과는 아니다.
사용기 평가 준비 2026-10-14 [S13]	manifest는 40편(정상 30, 비사용기 10)을 기록한다. 지시문 혼입 5편, 긴 글, 실제 사용자 글은 보완 필요로 명시했다.	선정·준비된 말뭉치의 범위다. 전체 40편의 모델 평가가 완료되었다는 뜻은 아니다.
저장된 모델 실행 [S13]	확인 시점 A1-1·F1 파일에 각각 1회 기록. A1-1: 22개 항목, 51.0초. F1: question으로 비분석 처리, 19.3초.	정답 대조와 반복 평가가 없으므로 정확도·F1·서비스 지연 대표값을 산출할 수 없다. 시간은 스크립트 실행 구간 값이다.

증거가 부족한 부분

전체 API 경로의 과제별 정답률, 근거 충실도, 반복 성공률, p95 지연, 요청당 비용 및 대체 API 모델과의 공정한 비교 결과는 이번 검토에서 완결된 보고서로 확인하지 못했다. 실호출 테스트 코드가 있어도 실행 로그가 없으면 "평가 준비"로 기재한다. [S11, S13]

src/config.py의 과거 비전 모델 비교 주석은 모델 선택의 내부 참고 기록으로 사용할 수 있다. 그러나 원본 입력·정답·응답·반복 결과를 함께 확인하지 않은 상태이므로 본 문서의 확정 성능 수치에는 포함하지 않았다. [S2]

결과 보고 원칙

엔진 검증 / API 원출력 품질 / 검증·폴백 이후 서비스 품질을 따로 집계한다. 폴백이 요청을 처리했더라도 API 모델의 실패를 성공으로 덮어 쓰지 않는다.

06 / 대체 모델 평가 설계

동일 조건에서 비교하는 평가 절차

이 장은 수행 계획이다. 신규 평가나 모델 호출을 실행하지 않았다.

1. 비교군과 변경 변수

비교군	고정 조건 및 비교 목적
B0 · 규칙 기준선	규칙 대체 경로가 있는 텍스트·대화 과제에서만 비교한다. 이미지 등 지원하지 않는 과제는 적용 불가로 표기한다.
B1 · 현재 API 구성	현재 설정의 모델, 프롬프트, 검색·도구, 검증기를 동결한 서비스 구성을 기준으로 삼는다.
B2 · 대체 API 모델	동일 입력·프롬프트·도구·출력 스키마에서 모델 식별자만 바꾼다. 실제 계정의 기능 지원을 확인한 모델을 선정한다.
별도 분석 · 검증 효과	같은 원출력의 검증 전·후를 비교하여 오류 차단률과 정상 결과의 과도한 차단률을 함께 본다.

2. 평가 데이터와 정답 작성

사용기 추출은 기존 40편을 출발점으로 삼되 원문 기준으로 정답을 다시 확정한다. 기존 작성 기획표는 "글을 이렇게 쓰려는 의도"이므로 실제 정답으로 바로 사용하지 않는다. 실제 글과 합성 예시를 구분하고, 부족한 지시문 혼입·장문·실사용자 사례를 별도 집단으로 추가한다. [S9, S13]

대화는 정답 도구·인자·최종 상태, 견적 추출은 부품별 원문·모델번호·가격·미기재 값, 검색은 질의별 관련 문서와 지원되는 주장을 라벨링한다. 개발용과 최종 평가용 데이터를 제품·문서·유사 이미지 단위로 분리하여 중복 유출을 막는다.

3. 반복, 판정 및 재현성

비결정적인 API 과제는 동일 입력을 원칙적으로 3회 반복한다. 사용기 40편이면 비교군당 120회 실행이지만 내부 재시도·추가 호출로 실제 과금 호출 수는 더 많을 수 있다. 모델별 지원 파라미터 차이와 검색 시점 차이를 기록하고, 가능한 경우 검색 근거를 고정해 모델 차이를 분리한다. [S11]

정답과 근거 충실도는 2인이 독립 검토하고 불일치를 조정하는 방식을 제안한다. 회차별 결과와 실패 원인을 모두 보존하며, 반복 입력을 독립 표본으로 과대 계산하지 않고 입력 단위 집계·신뢰구간을 함께 보고한다.

재현 기록: 코드 커밋·파일 해시, 모델 요청/응답 식별자, 프롬프트·스키마 버전, 데이터 해시, 기능 플래그, MOCK_MODE, 호출 시각, 원출력·검증 결과, 재시도·폴백, 토큰 사용량, 도구 사용 및 과금 근거.

07 / 지표와 판정

무엇을 측정하고 어떻게 보고할 것인가

아래 목표는 팀 검토를 위한 제안값이며, 달성 결과나 공식 평가 기준이 아니다.

평가 축	정의와 집계 방식	판정 제안
추출 정확성	부품 모델번호 등 필수 필드 정확 일치율 = 정답과 일치한 필드 / 전체 평가 필드. 누락·불필요한 추가 추출을 별도 집계.	필수 필드 95% 이상. 숫자·모델번호 오류는 사례별 별도 보고.
사용기·조건 분류	속성·방향·목적 등 사전 확정 라벨의 Precision, Recall, F1. 다중 라벨은 micro/macro 모두 보고.	핵심 라벨 macro-F1 0.90 이상. 희소 라벨별 표본 수 병기.
도구 실행 정확성	의도에 맞는 도구·인자·최종 상태가 모두 맞은 과제 수 / 전체 시도 과제 수. timeout과 오류도 분모에 포함.	95% 이상. 요청하지 않은 중요 상태 변경 0건.
근거 충실도	근거로 뒷받침되는 검증 가능 주장 수 / 전체 검증 가능 주장 수. 무응답은 별도 과제 실패·커버리지에 반영.	95% 이상. 제품·가격·호환성의 중대한 근거 없는 단정 0건.
검색 품질	Recall@5 = 상위 5개에 포함된 정답 문서 수 / 전체 정답 문서 수, 질의별 평균. 정답 없음 질의는 오탐률 별도.	Recall@5 0.90 이상. 작은 문서 집합·정답 누락의 영향 별도 해석.
실패·방어·안정성	API 오류율, 스키마 부적합률, 재시도율, 폴백률, 공격 성공률. 과제별 전체 시도를 분모로 보고.	중대한 검증 우회 0건. 실패를 숨기지 않고 정해진 오류·대체 경로 확인.
지연·비용	사용자 요청 전체의 p50/p95와 API 구간을 구분. 총 토큰·도구 비용 / 전체 요청, 성공 요청당 비용도 별도.	수치 목표는 팀의 UX·예산 기준 확정 후 적용. 캐시·동시성·재시도 조건 명시.

분류 계산: Precision=TP/(TP+FP), Recall=TP/(TP+FN), F1=2PR/(P+R). 분모가 0인 항목은 N/A로 표기하고 유효 표본 수를 밝힌다. 미기재 값의 정확한 null 처리와 환각 생성률도 함께 기록한다.

최종 채택 규칙 제안

우선 중대한 오판·검증 우회가 없는지 확인한다. 그다음 필수 과제 품질을 만족하는 모델 중 비용과 지연을 비교한다. 종합 평균이 높아도 특정 제품군·입력 유형의 반복 실패가 있으면 조건부 채택 또는 보완 대상으로 남긴다.

08 / 평가 기준과의 정합성

수행 범위와 대체 증거를 연결

공식 평가표를 확보하면 아래 항목을 실제 문구·배점에 대응시켜 갱신한다.

평가 관점(가정)	현재 제시할 증거	기재해야 할 한계
sLLM 학습·미세조정·자체 서빙	팀의 미수행 사유와 API 대체 구조. [S1-S4]	미수행. API 활용을 해당 실적으로 환산하거나 충족을 단정하지 않는다.
AI 기술 선정·문제 적합성	자연어 처리와 규칙 판정의 역할 분담, 기능별 모델 호출. [S3-S6]	API 우월성이나 sLLM 열세는 직접 비교 실험 없이 주장하지 않는다.
데이터·RAG·도구 활용	임베딩 검색, 도구 호출, 근거 검증, 사용기 구조화. [S4, S7-S9]	구현된 경로와 미연결·테스트 전용 경로를 구분하고 정답 기반 품질 평가를 추가한다.
정량 평가·재현성	기존 엔진 비교, 일부 실행 기록, 실호출 테스트 코드. [S10-S13]	현재 API 종합 점수는 미확정. 6~7장의 동일 조건 평가 결과와 원본 로그를 보강한다.
서비스 안정성·완성도	시간 제한, 동시성 제어, 검증, 기능별 실패 처리. [S3, S6, S10]	구현 존재와 운영 안정성 입증을 구분한다. 실환경 장애·부하 측정이 추가로 필요하다.

평가 제출용 설명 문안

기술 선택 및 미수행 설명

본 팀은 TrueFit 개발 과정에서 sLLM을 별도로 도입할 만큼 활용할 부분이 크지 않다고 판단하여 자체 sLLM 학습·서빙을 수행하지 않았습니다. 자연어 해석, 이미지 사양 추출, 근거 검색 및 설명 생성에는 관리형 모델 API를 활용하고, 추천 점수·호환성·예산 판단은 규칙 엔진으로 처리했습니다. API 출력은 구조 검증과 기능별 실패 처리로 통제합니다. 기존 엔진 검증 결과와 모델 실행 기록을 제시하되, 이를 sLLM 수행 실적이나 API 종합 성능 평가 완료로 주장하지 않습니다. API 품질은 동일 데이터·프롬프트·도구 조건에서 정확성, 근거 충실도, 안정성, 지연 및 비용으로 분리 평가하는 방안을 제시합니다.

최종 제출 전 보완할 자료

공식 평가표 원문과 해당 항목·배점, 실제 배포 모델·활성화 설정, 데이터·정답 확정본, 회차별 실호출 결과와 지표표를 묶어 제출한다. sLLM 수행 자체가 필수 항목이라면 미충족 범위를 명시하고 대체 증거의 인정 여부를 평가 담당자에게 확인한다.

09 / 근거 목록

저장소 및 확인 출처

경로는 C:/web_workspace/skn_final 기준이다. 대괄호 번호로 본문 주장과 연결된다.

[S1] 팀 의사결정 확인
2026-10-14 본 대화 사용자 답변: 개발 과정에서 sLLM의 활용 필요성이 크지 않다고 판단하여 사용하지 않음. 별도 회의록을 확인한 것은 아니다.

[S2] 모델·모드·기능 설정
src/config.py; .env.example. LLM_MODEL, SPEC_EXTRACTION_IMAGE_MODEL, MOCK_MODE, 기능 플래그, 임베딩 설정. 실제 .env 및 비밀키는 열람하지 않았다.

[S3] API 호출·출력·검색
src/clients/llm_client.py. _get_client, _call_openai, _call_openai_vision, _call_openai_web_search, _create_within. src/clients/llm_guard.py.

[S4] 대화 에이전트
src/agent/conditions_agent.py (_model); src/agent/result_agent.py; src/agent/quote_review_agent.py. API 모델·활성 조건·도구 사용 경계.

[S5] 핵심 역할 분담
docs/기획서_0930_개발기준.md §2 원칙 P1 및 견적 점검 설명. 역사적 기획 문서이므로 현재 동작은 관련 코드와 함께 해석했다.

[S6] 추출·검증·설명
src/agent/spec_extraction_agent.py; src/engine/stage5_explain.py. 추출 전용 스키마, 이미지·텍스트 경계, model_validate, 규칙 설명 폴백.

[S7] 검색 후 근거 검증
src/services/live_spec_lookup.py; docs/미보유부품_실시간스펙검색_설계.md 배경·설계 원칙. 문서의 초기 미착수 표기보다 현재 코드의 구현 존재를 우선했다.

[S8] 임베딩 및 검색 범위
src/rag/embedding.py; src/rag/care_guides.py; src/rag/__init__.py; src/services/review_search.py; src/services/peripheral_evidence_embedding.py; src/workers/review_embedding_batch.py.

[S9] 사용기 추출·평가 한계
src/agent/peripheral_post_agent.py; src/engine/peripheral_post_eval.py; scripts/eval_peripheral_post_extraction.py. 기획 정답표와 실제 원문 정답의 차이를 명시한다.

[S10] 보호 장치 테스트
tests/test_llm_guard.py; tests/test_llm_deadline.py. 동시성·제한 시간·재시도·규칙 폴백의 테스트 정의. 이번 작업에서 실행하지 않았다.

[S11] 실호출과 회귀의 구분
AGENTS.md; pyproject.toml; docs/전체_테스트_시나리오_실행_기획.md §2.5·§13; tests/test_spec_extraction_llm_live.py; tests/test_chat_llm_live.py; tests/test_review_embedding_llm_live.py.

[S12] 기존 엔진 평가 결과
docs/validation/engine_policy_compare_20261012.md (본문 작성일 2026-10-13), §3·§4.8 및 고정 시나리오 표. 동명 baseline/after/scenarios JSON 경로가 보고서에 기록되어 있다.

[S13] 평가 준비·원출력 기록
data/eval_extraction/manifest.json; data/eval_extraction/model_runs/A1-1.json; data/eval_extraction/model_runs/F1.json; scripts/eval_extraction_run.py. 문서 작성 중 읽은 시점의 기록이다.

해석 원칙: 사용자 확인, 코드 구현, 과거 실행 기록, 향후 제안을 구분했다. 공식 평가표·현재 운영 로그·새 실험 결과가 없는 항목은 미확인 또는 계획으로 남겼다. 외부 모델의 최신 가격·출시 정보나 일반 성능 수치를 인용하지 않았다.